

二、极大似然估计法

引例 袋中放有黑球和白球共4个，今有放回地抽球三次，得到白、白、黑球，试估计袋中白球数。

解 设 m 为白球个数，总体 $X \sim B(1, m/4)$. $EX = m/4$,

$$m = 4EX, \hat{m}_1 = 4\bar{x} = 4 \cdot \frac{x_1 + x_2 + x_3}{3} = \frac{8}{3}. X = \begin{cases} 1, & \text{取出一球为白球} \\ 0, & \text{取出一球为黑球} \end{cases}$$

取到白、白、黑球的概率为

$$\left(\frac{m}{4}\right)^2 \left(1 - \frac{m}{4}\right) = \begin{cases} 3/64, & m=1 \\ 8/64, & m=2 \\ 9/64, & m=3 \\ 0, & m=0, 4 \end{cases}$$

当 $m = 3$ 时，观察值出现的概率最大，故 $\hat{m}_2 = 3$ 。

极大似然估计：参数空间中使样本观察值出现的概率或概率密度达到最大的参数。

似然函数：设样本观察值为 $x_1, x_2, \dots, x_n$ ，则

$$L(x_1, x_2, \dots, x_n; \theta) = \begin{cases} \prod_{i=1}^n P_{\theta}(X = x_i) & \text{其中 } P_{\theta}(X = x_i) \text{ 为 } X \text{ 的分布律} \\ \prod_{i=1}^n f(x_i, \theta) & \text{其中 } f(x, \theta) \text{ 为 } X \text{ 的密度函数} \end{cases}$$

θ 的极大似然估计值 $\hat{\theta}(x_1, x_2, \dots, x_n)$ ：

$$L(\hat{\theta}) = \max_{\theta \in \Theta} L(\theta) \Leftrightarrow \ln L(\hat{\theta}) = \max_{\theta \in \Theta} \ln L(\theta) \quad (\text{自变量 } \theta)$$

通常由**似然方程** $\frac{\partial \ln L(\theta)}{\partial \theta_i} = 0 \quad i = 1, 2, \dots, l$ 解出 $\hat{\theta}_i$

注 若无驻点，则在 θ 的不可导点或边界点处达到。

θ 的极大似然估计量 $\hat{\theta}(X_1, X_2, \dots, X_n)$ 。

例1 设寿命 $X \sim E(1/\theta)$, 试由下面18个样本观察值求未知参数 θ 的极大似然估计值。

$$\text{解 } L(\theta) = \prod_{i=1}^n \left(\frac{1}{\theta} e^{-\frac{x_i}{\theta}} \right) = \frac{1}{\theta^n} e^{-\frac{1}{\theta} \sum_{i=1}^n x_i}, \quad x_i > 0, \quad i = 1, 2, \dots, n$$
$$\frac{d}{d\theta} \ln L = \frac{d}{d\theta} \left[-n \ln \theta - \frac{1}{\theta} n \bar{x} \right] = -\frac{n}{\theta} + \frac{n}{\theta^2} \bar{x} = 0$$

解得估计值 $\hat{\theta} = \bar{x} = 317.94$, 估计量 $\hat{\theta} = \bar{X}$, 与矩估计相同。

例2 已知 X 的分布列为

X	1	2	5
P	p^2	$p(1-p)$	$1-p$

求参数 p 的极大似然估计。

解 设 n 次中观察到1、2、5的次数分别为 n_1 、 n_2 、 n_3 , 则

$$L(p) = (p^2)^{n_1} [p(1-p)]^{n_2} (1-p)^{n_3}, \text{ 求对数似然函数的驻点即可}$$

例3 设总体 $X \sim N(\mu, \sigma^2)$, 求 μ 和 σ^2 的极大似然估计值

解
$$L(\mu, \sigma^2) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x_i - \mu)^2}{2\sigma^2}} = (2\pi\sigma^2)^{-\frac{n}{2}} e^{-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2}$$

$$\ln L = -\frac{n}{2} [\ln(2\pi) + \ln \sigma^2] - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2$$

$$\begin{cases} \frac{\partial}{\partial \mu} \ln L = \frac{1}{\sigma^2} \sum_{i=1}^n (x_i - \mu) = \frac{1}{\sigma^2} (n\bar{x} - n\mu) = 0 \\ \frac{\partial}{\partial \sigma^2} \ln L = -\frac{n}{2} \cdot \frac{1}{\sigma^2} + \frac{1}{2\sigma^4} \sum_{i=1}^n (x_i - \mu)^2 = 0 \end{cases}$$


$$\Rightarrow \hat{\mu} = \bar{x}, \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 = \tilde{s}^2 \text{ 与矩估计相同}$$

问题: 若 μ 已知, 则 $\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \mu)^2 \neq \tilde{s}^2$

例4 设总体 $X \sim U[a, b]$, 试求 a 和 b 的极大似然估计量

解
$$L(a, b) = \prod_{i=1}^n f(x_i; a, b) = \frac{1}{(b-a)^n}, x_i \in [a, b], i = 1, 2, \dots, n$$

$\therefore$ 在 $a \leq x_1, x_2, \dots, x_n \leq b$ 下(注意自变量为 a, b),



注 观测值提示了参数的范围。 $b-a$ 取min时, $L(a, b)$ 取max.

$\therefore$ 当 $a = \min_{1 \leq i \leq n} \{x_i\}, b = \max_{1 \leq i \leq n} \{x_i\}$ 时, $L(a, b) = \max$

即 a, b 的极大似然估计值为 $\hat{a} = x_1^*, \hat{b} = x_n^*$ 与矩估计不同
及 a, b 的极大似然估计量为 $\hat{a} = X_1^*, \hat{b} = X_n^*$

问题 估计量的分布函数? 密度? 期望、方差?

性质：若 $\hat{\theta}$ 为 θ 的极大似然估计，则 $u(\hat{\theta})$ 为 $u(\theta)$ 的极大似然估计。**不变性→密度、概率的估计等**

由例3知，正态总体 μ 未知时： $\hat{\sigma}^2 = \tilde{S}^2$ ，故

$$\hat{\sigma} = \tilde{S} = \sqrt{\frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2}$$

§ 7.3 估计量的评选原则

一、无偏性(n 固定)

若 $E(\hat{\theta})=\theta$ ，则称 $\hat{\theta}$ 为 θ 的无偏估计量。

例1 证明样本均值 $\bar{X}$ 为总体期望 $\mu=E(X)$ 的无偏估计。

解
$$E(\bar{X}) = \frac{1}{n} \sum_{i=1}^n E(X_i) = E(X) = \mu$$

一般
$$E(A_k) = E\left(\frac{1}{n} \sum_{i=1}^n X_i^k\right) = \frac{1}{n} \sum_{i=1}^n E(X_i^k) = E(X^k) = \alpha_k$$

即 k 阶样本原点矩 A_k 为 k 阶理论原点矩 α_k 的无偏估计。

例2 证明样本方差 $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$ 是总体方差 $D(X) = \sigma^2$ 的无偏估计。

问题 常用分布 $E(S^2) = ?$

证明 (1) 直接求 $E(X_i - \bar{X}) = 0$

$$D(X_i - \bar{X}) = D(X_i) + D(\bar{X}) - 2Cov(X_i, \bar{X}) = (n-1)\sigma^2 / n$$

$$\text{故 } E(S^2) = \frac{1}{n-1} \sum_{i=1}^n E(X_i - \bar{X})^2 = \frac{n}{n-1} [D(X_i - \bar{X}) + E^2(X_i - \bar{X})] = \sigma^2$$

$$(2) E(S^2) = E\left[\frac{1}{n-1} \left(\sum_{i=1}^n X_i^2 - n\bar{X}^2\right)\right] = \frac{1}{n-1} [nE(X^2) - nE(\bar{X}^2)]$$

$$\begin{aligned} \frac{D(X) = E(X^2) - (EX)^2}{\rightarrow} &= \frac{1}{n-1} [n(\sigma^2 + \mu^2) - n(D(\bar{X}) + E^2(\bar{X}))] \\ &= \frac{1}{n-1} [n\sigma^2 + n\mu^2 - n(\sigma^2 / n + \mu^2)] = \sigma^2 \end{aligned}$$

例 对正态总体的 n 个样本求 k 使 $k \sum_{i=1}^{n-1} |X_{i+1} - X_i|$ 为 σ 的无偏估计

解 $Z_i = X_{i+1} - X_i \sim N(0, 2\sigma^2)$, 故

由无偏性

$$E|Z_i| = \int_{-\infty}^{+\infty} |z| \frac{1}{\sqrt{2\pi} \cdot 2\sigma} e^{-z^2/(4\sigma^2)} dz = 2\sigma / \sqrt{\pi} \Rightarrow k = \frac{\sqrt{\pi}}{2(n-1)}$$

定理4.1

注1 例2说明 $\tilde{S}^2$ 不是 σ^2 的无偏估计 ~ 渐近无偏估计

$$\because E(\tilde{S}^2) = E\left(\frac{n-1}{n} S^2\right) = \frac{n-1}{n} \sigma^2 \xrightarrow{n \rightarrow \infty} \sigma^2$$

注2 $\hat{\theta}$ 为 θ 的无偏估计, 但 $g(\hat{\theta})$ 不一定是 $g(\theta)$ 的无偏估计。

一般, 函数的期望不等于期望的函数, 即 $E(g(\hat{\theta})) \neq g(E(\hat{\theta}))$ 。

如: 若 $D(X) > 0$, 虽 $\bar{X}$ 为 $\mu = E(X)$ 的(矩)无偏估计, 但 $\bar{X}^2$

(是)非 μ^2 的(矩)无偏估计。

$$\because E(\bar{X}^2) = D(\bar{X}) + [E(\bar{X})]^2 = \frac{\sigma^2}{n} + \mu^2 \neq \mu^2 \rightarrow \mu^2 \text{ 渐近无偏}$$

注3 无偏估计不唯一, 如 X_i 和 $\bar{X}$ 均为 $\mu = E(X)$ 的无偏估计。

事实上对任何 $c_1, c_2, \dots, c_n$, 当 $c_1 + c_2 + \dots + c_n = 1$ 时, 有

$$E\left(\sum_{i=1}^n c_i X_i\right) = \sum_{i=1}^n c_i E(X_i) = \sum_{i=1}^n c_i \cdot \mu = \mu$$

二、有效性(n 固定)

若 $E(\hat{\theta}_1) = E(\hat{\theta}_2) = \theta$, 且 $D(\hat{\theta}_1) \leq D(\hat{\theta}_2)$, 则称 $\hat{\theta}_1$ 比 $\hat{\theta}_2$ 有效

比如 $E(X_i) = E(\bar{X}) = \mu$, 但 $D(X_i) = \sigma^2$, $D(\bar{X}) = \frac{1}{n} \sigma^2$

故 $\hat{\mu} = \bar{X}$ 比 $\hat{\mu}_i = X_i$ 有效。

$\hat{\theta}_0$ 为 θ 的**最小方差无偏估计量** ~

$E(\hat{\theta}_0) = \theta$, 且对 θ 的一切无偏估计 $\hat{\theta}$ 有:

$$D(\hat{\theta}_0) \leq D(\hat{\theta})$$

三、均方误差(n 固定)

$E(\hat{\theta} - \theta)^2 = (E\hat{\theta} - \theta)^2 + D(\hat{\theta})$ 越小越好

四、一致性

若 $\forall \varepsilon > 0$, 有 $\lim_{n \rightarrow \infty} P(|\hat{\theta}_n - \theta| < \varepsilon) = 1$
则称 $\hat{\theta}_n$ 为 θ 的一致估计。

例4 由辛钦大数定律 $\lim_{n \rightarrow \infty} P(|\bar{X}_n - \mu| < \varepsilon) = 1$
知样本均值 $\bar{X}_n$ 是总体均值 μ 的一致估计。

例5 证明正态总体的样本方差 S_n^2 是 σ^2 的一致估计。

证 $\chi^2 = \frac{n-1}{\sigma^2} S_n^2 \sim \chi^2(n-1), E(S_n^2) = \frac{\sigma^2}{n-1} E(\chi^2) = \sigma^2$

$$D(S_n^2) = \frac{\sigma^4}{(n-1)^2} D(\chi^2) = \frac{2\sigma^4}{(n-1)}$$

由切比雪夫不等式 $1 \geq P(|S_n^2 - \sigma^2| < \varepsilon) \geq 1 - \frac{2\sigma^4}{(n-1)\varepsilon^2} \xrightarrow[n \rightarrow \infty]{} 1$
和夹挤定理得证。

练习 1 求总体 $P(\lambda)$ 和 $E(\lambda)$ 中参数 λ 的矩估计和极大似然估计量, 并判断无偏性。

解 1 $X \sim P(\lambda)$, 则 $E(X) = \lambda$, $\hat{\lambda} = \hat{E}X = \bar{X}$.

$$L(\lambda) = \prod_{i=1}^n \frac{\lambda^{x_i}}{x_i!} e^{-\lambda} = \lambda^{\sum_{i=1}^n x_i} e^{-n\lambda} / \prod_{i=1}^n x_i!$$

由 $d \ln(L(\lambda)) / d\lambda = 0 \Rightarrow \hat{\lambda} = \bar{x}, \hat{\lambda} = \bar{X}$.

由 $E(\hat{\lambda}) = E(\bar{X}) = \lambda$ 知, 估计量无偏。

2 $X \sim E(\lambda)$, 易得 $\hat{\lambda} = 1 / \hat{E}X = 1 / \bar{X}$.

$E(\hat{\lambda}) = \frac{n}{n-1} \lambda$ (超范围, 略) $\neq 1 / \hat{E}\bar{X} = \lambda$, 渐近无偏

(练习17.5 正态总体 $\mu=1$) ①求似然估计得: $\hat{\sigma} = \sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - 1)^2}$

② $P(\bar{X} < t) = F(t) = \Phi\left(\frac{t-1}{\sqrt{\sigma^2/n}}\right) = \Phi\left(\frac{t-1}{\sigma/\sqrt{n}}\right)$; ③ 代估计

问题: 总体密度的极大似然估计?